

Introdução

Eventos meteorológicos extremos são cada vez mais comuns, assim para garantir a segurança da população torna-se cada vez mais necessário ter modelos mais precisos, que possam informar política pública. Um método que permite tais previsões é o da Krigagem, uma técnica de interpolação geoestatística usada para estimar valores de uma variável em locais não observados baseados em locais amostrados. A aplicação de tal técnica permite melhores previsões de vários fenômenos naturais como a chuva e temperatura que são importantes indicadores de eventos extremos. O objetivo desse trabalho é estimar a distribuição espacial da precipitação e temperatura no estado do Rio Grande do Sul no mês de fevereiro de 2025, para isso serão considerados dados meteorológicos coletados em 40 centros de monitoramento espalhados no estado [Met25].

Metodologia

Para a estimativa da precipitação e da temperatura será utilizado o modelo geoestatístico tal que a variável de interesse $Z(s)$ na localização $s \in D \subset \mathbb{R}^2$ é considerada como a realização do seguinte processo estocástico [Cre15]:

$$Z(s) = \mu + \varepsilon(s), \quad (1)$$

- μ média constante desconhecida;
- $\varepsilon(s) \sim \mathcal{N}(0, C(h))$ é um processo estacionário com esperança zero e função de covariância $C(h) = \text{Cov}(Z(s), Z(s+h))$ que é dependente da distância h .

Sob essas condições, utilizou-se a krigagem ordinária, um estimador linear e não viciado definido pela Equação: 2:

$$\hat{Z}(s_0) = \sum_{i=1}^n \lambda_i Z(s_i), \quad (2)$$

- $\hat{Z}(s_0)$ é o valor predito na localização s_0 ;
- $Z(s_i)$ representa o valor observado da variável no local s_i ;
- λ_i é o peso atribuído ao valor observado $Z(s_i)$.

Semivariograma

Nesse modelo é importante definir a função do semivariograma $\hat{\gamma}(h)$, que indicará a estrutura da função de covariância $C(h)$, que descreve a dependência espacial do processo. Uma forma de estimar o semivariograma não parametricamente é através da Equação

$$\hat{\gamma}(h) = \frac{1}{2N(h)} \sum_{i=1}^{N(h)} (Z(s_i) - Z(s_i+h))^2. \quad (3)$$

- $N(h)$ é o número de pares de dados que estão separados pela distância h .

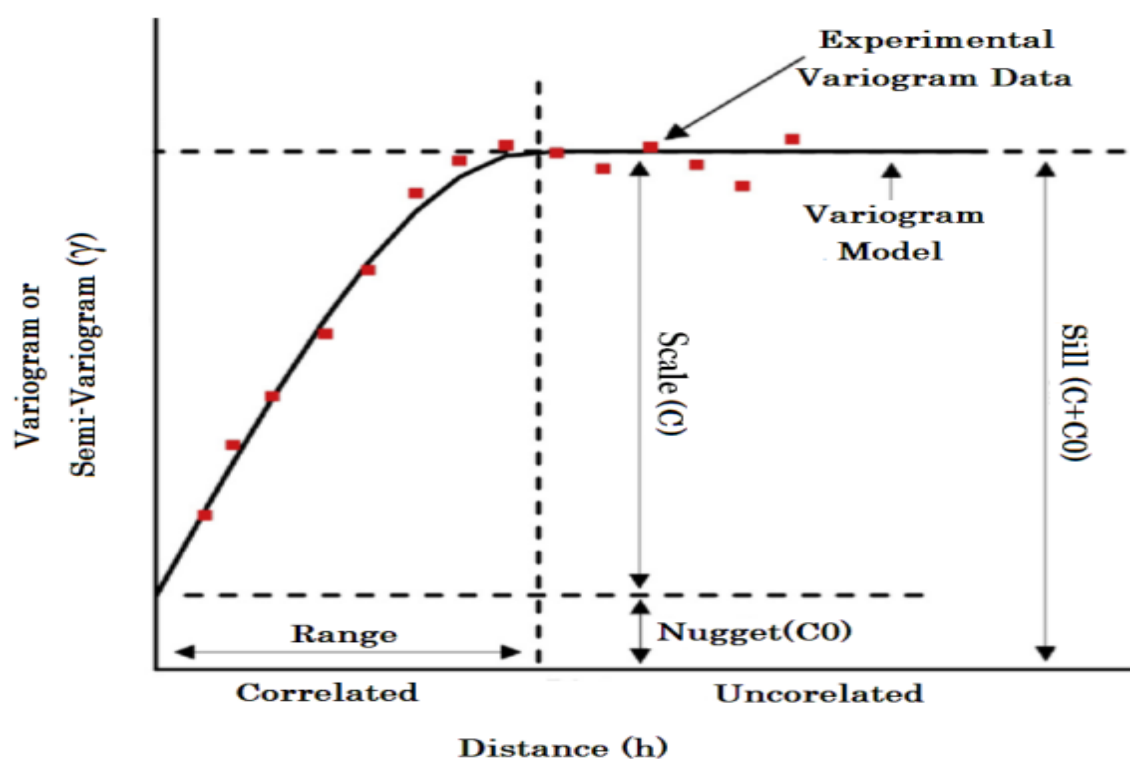


Figura 1. Parâmetros de um variograma e/ou semi variograma Fonte: Bagheri Bodaghabadi (2018). [Bag18]

Para o cálculo do variograma foi utilizada a função **VGM** e para krigagem foi utilizada a função **krige**, ambas do pacote **gstat** [GPH16]. A Figura 2 apresenta duas estimativas da precipitação para uma grade regular no RS usando modelos com variogramas de dois ângulos distintos.

Para a confecção das imagens da Figura 2 foi utilizado o pacote **Leaflet**[Che+24].

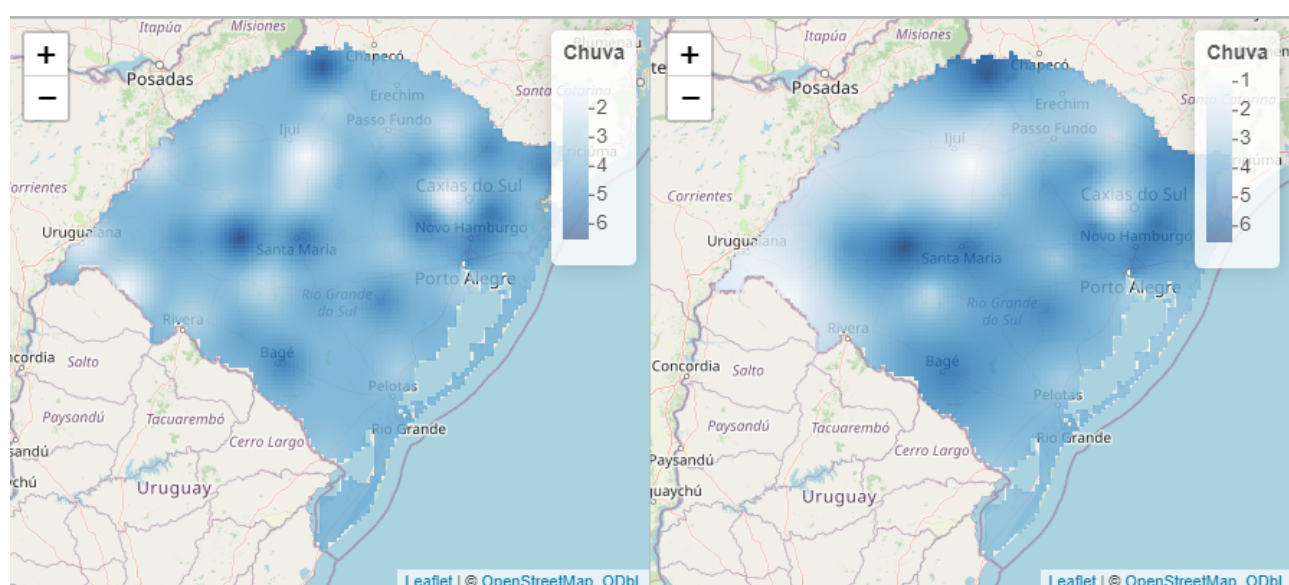


Figura 2. Diferente estimativas da precipitação, considerando uma diferentes ângulos para a função de covariância isotrópica. Fonte: Do autor

O uso de ângulos distintos é importante pois vários fenômenos físicos que acontecem no espaço são anisotrópicos, isso é temos diferentes relações entre a variável e a distância do ponto dependendo da direção em que estamos olhando. Na direita vemos a estimativa que faz uso do variograma com ângulo de 135 graus, enquanto, na direita, temos a predição considerando um ângulo de 90 graus. A função de covariância escolhida pela função *fit.variogram* do pacote *gstat*, foi a função esférica para ambos os casos, e os parâmetros do modelo foram estimados numericamente pela mesma função.

Resultados

A Figura 3 apresenta a distribuição espacial estimada da precipitação, temperatura, vento e umidade no estado do Rio Grande do Sul. Observa-se um padrão espacial, com maiores valores de precipitação concentrados à esquerda da lagoa dos patos, enquanto as temperaturas mais elevadas são verificadas nas regiões próximas a Porto Alegre e noroeste do estado. Os modelos do vento e umidade tiveram interpolações que apenas diferem da média imediatamente na região próxima de uma estação. Melhores resultados para tais variáveis poderiam ser encontrados com algoritmos mais robustos de estimação de parâmetros, como o método da máxima verossimilhança.

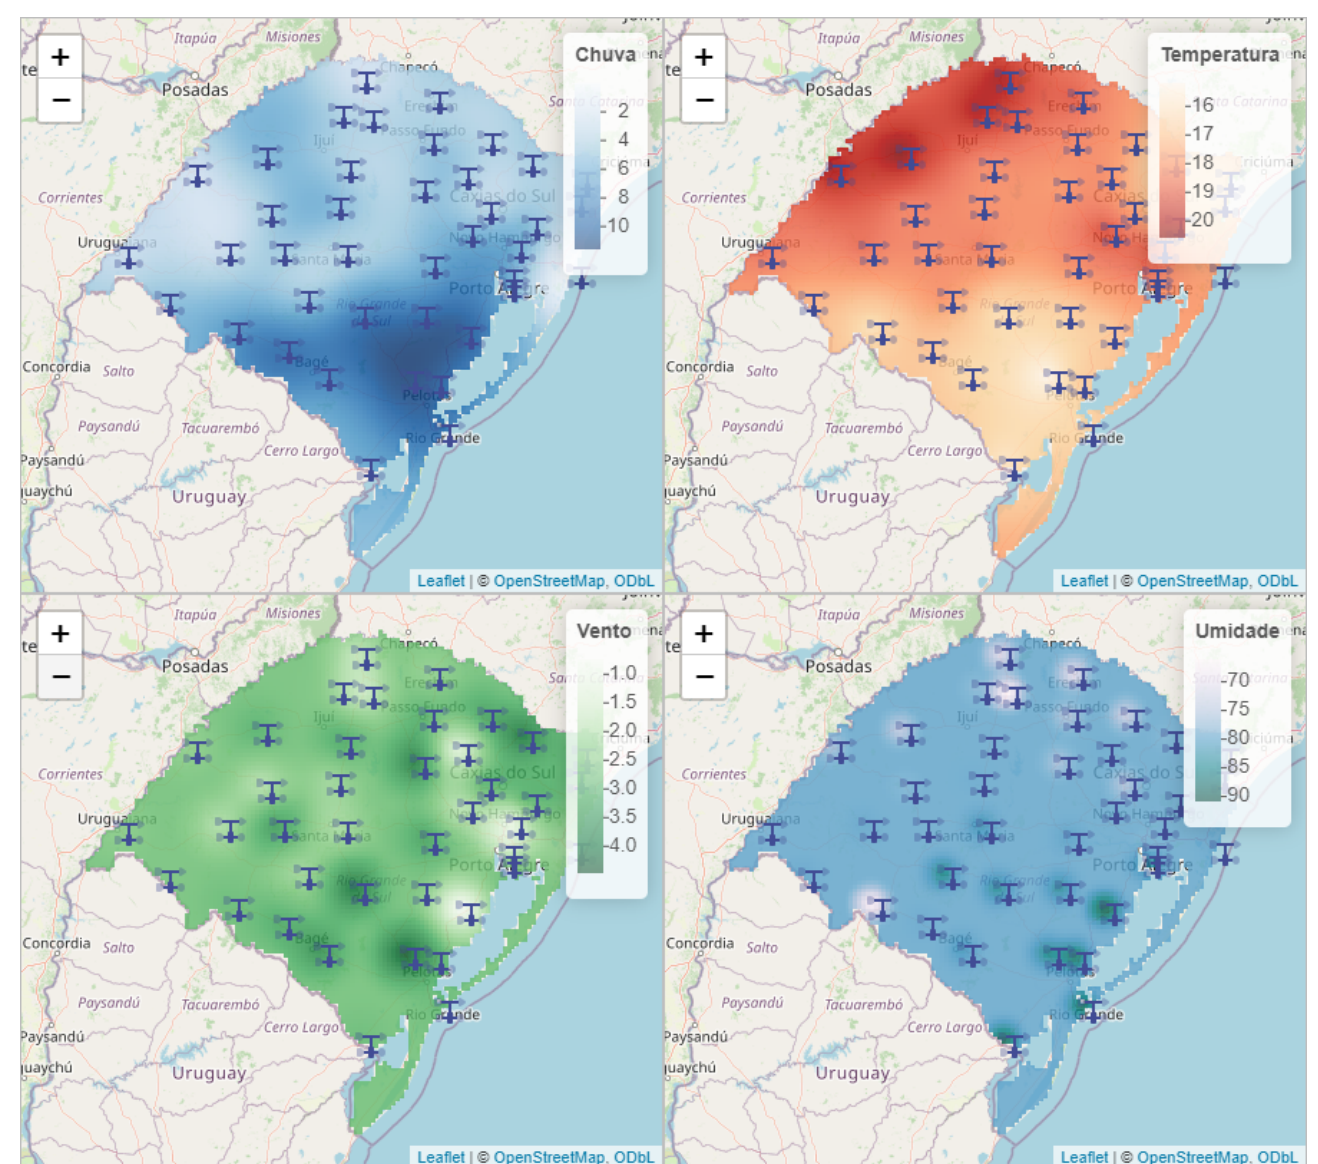


Figura 3. Krigagem ordinária com chuva, temperatura, vento e umidade no Rio Grande do Sul. Fonte: Do autor

Conclusão

A estimativa adequada dessas variáveis é de fundamental importância para o monitoramento climático, contribuindo para a identificação de áreas de risco, a formulação de estratégias de mitigação de impactos extremos e o planejamento de ações adaptativas frente às mudanças climáticas.

Referências

- Bagheri Bodaghabadi, M. "Is it necessarily a normally distributed data for kriging? A case study: soil salinity map of Ghahab area, central Iran". Em: *Desert* 23.2 (2018), pp. 284–293.
- Cheng, Joe et al. *leaflet: Create Interactive Web Maps with the JavaScript 'Leaflet' Library*. R package version 2.2.2. 2024. URL: <https://CRAN.R-project.org/package=leaflet>.
- Cressie, Noel. *Statistics for spatial data*. John Wiley & Sons, 2015.
- Gräler, Benedikt, Edzer Pebesma e Gerard Heuvelink. "Spatio-Temporal Interpolation using gstat". Em: *The R Journal* 8 (1 2016), pp. 204–218. URL: <https://journal.r-project.org/archive/2016/RJ-2016-014/index.html>.
- Meteorologia (INMET), Instituto Nacional de. *Tabela de Estações Meteorológicas*. Acesso em: 16 mar. 2025. 2025. URL: <https://tempo.inmet.gov.br/TabelaEstacoes/A001>.
- Pebesma, Edzer J. "Multivariable geostatistics in S: the gstat package". Em: *Computers Geosciences* 30 (2004), pp. 683–691.
- R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria, 2024. URL: <https://www.R-project.org/>.

Agradecimentos

Agradecemos à FAPERGS por viabilizar este projeto (24/2551-0002361-5) através do Edital 06/2024 - Programa de Pesquisa e Desenvolvimento Voltado a Desastres Climáticos